

Relatorio de Eficiencia do Modelo AlimempatIA -- Versao 2

Integrantes do Grupo

- Bernardo Seijas Cavalcante - 24026290
- Eduardo Chen Zou - 24025817
- Fabiano Henrique Chou - 24025991
- Nicolas Roberto Jordan Morales - 24025897

1. Introducao

Este relatorio apresenta uma analise da eficiencia do modelo de deteccao de objetos **AlimempatIA**, desenvolvido para identificar produtos alimenticios da cesta basica em tempo real. O modelo foi treinado utilizando a arquitetura **YOLOv8n** (variante Nano), otimizada para inferencia rapida em dispositivos com recursos limitados. Os resultados aqui descritos referem-se ao treinamento da **versao 2 (v2)** do modelo, denominada internamente de **train_slim**.

As classes detectadas pelo modelo sao:

Indice	Classe
0	Arroz
1	Feijao
2	Acucar
3	Macarrao
4	Fuba
5	Oleo
6	LeiteEmPo

2. Configuracao do Treinamento

O treinamento foi conduzido com os seguintes parametros principais:


Parametro	Valor
Modelo base	YOLOv8n (Nano)
Epocas	40
Tamanho da imagem	512x512 pixels
Batch size	16
Dispositivo	GPU (device 0)

Parametro	Valor
Otimizador	Automatico (auto)
Learning rate	0.01 (inicial)
Peso pre-treinado	Sim (pretrained)
Mosaic	Ativado (1.0)
Augmentacao	RandAugment
Precisao mista	Sim (AMP)

A utilizacao da variante Nano do YOLOv8 foi uma escolha deliberada visando equilibrar desempenho e velocidade de inferencia, dado que o modelo deve operar em cenarios de deteccao em tempo real via camera.

3. Evolucao do Treinamento

O grafico abaixo consolida as curvas de perda (loss) de treinamento e validacao, alem das metricas de precisao, recall e mAP ao longo das 40 epocas:



3.1. Perdas de Treinamento

As tres funcoes de perda monitoradas durante o treinamento (box_loss, cls_loss e dfl_loss) apresentaram queda consistente ao longo das epocas:

- **Box Loss (perda de localizacao):** Reduziu de 0.875 na epoca 1 para 0.364 na epoca 40, indicando que o modelo aprimorou significativamente sua capacidade de localizar os objetos nas imagens.
- **Classification Loss (perda de classificacao):** Apresentou a maior reducao proporcional, caindo de 3.091 para 0.468. Isso demonstra que o modelo aprendeu efetivamente a distinguir entre as sete classes de alimentos.

- **DFL Loss (perda de distribuicao focal):** Reduziu de 1.316 para 0.987, mostrando melhora na precisao das bordas das caixas delimitadoras.

3.2. Perdas de Validacao

As perdas de validacao acompanharam a tendencia de queda das perdas de treinamento, o que indica ausencia de overfitting significativo:

- **Val Box Loss:** De 0.884 para 0.445.
- **Val CIs Loss:** De 3.161 para 0.686.
- **Val DFL Loss:** De 1.238 para 0.970.

A aproximacao entre as curvas de treinamento e validacao sugere que o modelo generalizou adequadamente para dados nao vistos durante o treino.

4. Metricas Finais de Desempenho

Ao final das 40 epocas de treinamento, o modelo atingiu as seguintes metricas globais:

Metrica	Valor Final
Precision	85.19%
Recall	85.45%
mAP@0.5	86.26%
mAP@0.5:0.95	77.26%


Estes valores sao considerados satisfatorios para um modelo da categoria Nano, que prioriza velocidade sobre acuracia maxima. O mAP@0.5 de 86.26% indica que, em media, o modelo identifica corretamente os produtos alimenticios em mais de 86% das vezes quando considerado um limiar de IoU de 50%.

O mAP@0.5:0.95 de 77.26% revela que, mesmo sob criterios mais rigorosos de sobreposicao entre a caixa predita e a caixa real, o modelo mantem um desempenho robusto.

5. Analise por Classe

5.1. Curva Precision-Recall

A curva Precision-Recall abaixo detalha o desempenho individual de cada classe:



Os valores de AP (Average Precision) por classe, extraídos da curva, são:

Classe	AP@0.5
Arroz	98.2%
Feijao	62.8%
Acucar	91.3%
Macarrao	83.5%
Fuba	94.1%
Oleo	99.3%
LeiteEmPo	86.1%
Media	87.9%

Apontamentos:


- **Oleo** e **Arroz** foram as classes com melhor desempenho, atingindo AP superiores a 98%. Isso pode ser atribuído às características visuais distintas dessas embalagens (formato de garrafa para o óleo e pacote padronizado para o arroz), que facilitam a detecção.
- **Feijao** apresentou o menor AP (62.8%), o que representa o principal ponto de atenção do modelo. A queda de desempenho nessa classe pode estar relacionada à similaridade visual entre embalagens de feijão e outros produtos, ou a uma menor representatividade dessa classe no conjunto de dados de

treinamento. Conforme a matriz de confusao normalizada, 28% das amostras reais de feijao foram classificadas como background, indicando falhas na deteccao.

- **Fuba** alcançou um AP elevado de 94.1%, porem a matriz de confusao indica pequenas confusoes com feijao (4%) e acucar (9%), possivelmente devido a semelhancas nas cores das embalagens.

5.2. Curva F1-Confidence

A curva F1 em funcao do limiar de confianca revela o ponto de equilibrio ideal entre precisao e recall:




O F1-Score maximo medio foi de **0.84**, alcançado em um limiar de confianca de **0.696**. Isso significa que, ao configurar o modelo para reportar apenas deteccoes com confianca superior a aproximadamente 70%, obtem-se o melhor balanço entre falsos positivos e falsos negativos.


Destaca-se que a classe **Oleo** mantém um F1-Score acima de 0.90 em uma ampla faixa de confianca (de 0.2 a 0.9), o que confirma a robustez da deteccao dessa classe. Ja a classe **Feijao** apresenta valores de F1 consideravelmente mais baixos ao longo de toda a curva, reafirmando a necessidade de melhoria no treinamento para essa categoria.

6. Matriz de Confusao

A matriz de confusao normalizada permite avaliar onde o modelo acerta e onde comete erros sistematicos:



A matriz de fusao em valores absolutos complementa a analise:




Apontamentos sobre a matriz de confusao:

- **Oleo** obteve 100% de acerto na diagonal principal, sem qualquer confusao com outras classes. Este e o melhor resultado individual do modelo.
- **Arroz** apresentou 96% de acerto, com uma pequena confusao de 14% oriunda de amostras de Acucar erroneamente classificadas como Arroz. Essa confusao pode ser explicada pela semelhanca das embalagens brancas de ambos os produtos.
- **Macarrao** atingiu 91% de acerto na classificacao, demonstrando boa capacidade de discriminacao.
- **LeiteEmPo** alcançou 88% de acerto, com 9% de falsos positivos provenientes do background. Isso indica que, em alguns casos, elementos do fundo da imagem sao erroneamente detectados como LeiteEmPo.
- **Fuba** obteve 79% de acerto, com confusoes menores oriundas de Feijao (4%) e Acucar (9%).
- **Acucar** registrou 73% de acerto, com 10% de falsos positivos do background e confusao com Fuba (4%).
- **Feijao** foi a classe com maior taxa de erro: apenas 68% de acerto, com 28% das amostras sendo classificadas como background (nao detectadas) e 40% dos falsos positivos vindo do background. Esse resultado reforca que a classe Feijao necessita de maior volume de dados de treinamento ou maior diversidade de amostras.

7. Deteccoes em Imagens Reais


As imagens a seguir demonstram o modelo em funcionamento sobre capturas reais de camera, validando seu desempenho pratico em cenarios do mundo real.

7.1. Deteccao de Acucar




O modelo identificou corretamente uma embalagem de acucar da marca Alto Alegre com confianca de 79%. A caixa delimitadora abrangeu adequadamente toda a extensao do produto, demonstrando boa localizacao espacial.

7.2. Deteccao de Macarrao



O macarrao da marca Adria foi detectado com confianca de 68%. Embora o valor de confianca seja moderado, a deteccao foi correta tanto na classificacao quanto na localizacao. A confianca ligeiramente inferior pode ser explicada pela iluminacao lateral e pelo fundo parcialmente escuro da imagem.

7.3. Deteccao de Oleo



O óleo de soja da marca Liza foi identificado com 76% de confiança. A caixa delimitadora enquadrando corretamente a garrafa, apesar da presença de sombra e reflexos na embalagem transparente, que podem dificultar a detecção.

8. Considerações Finais

O modelo AlimempatIA v2, baseado na arquitetura YOLOv8n, demonstrou eficiência satisfatória na detecção de 7 classes de produtos alimentícios da cesta básica. Com um mAP@0.5 de 87.9% e mAP@0.5:0.95 de 77.26%, o modelo apresenta um bom equilíbrio entre acurácia e velocidade de inferência.

Os principais pontos de destaque são:

1. **Classes com alto desempenho:** Óleo (99.3% AP), Arroz (98.2% AP) e Fuba (94.1% AP) foram consistentemente bem detectados, com baixíssimas taxas de confusão.
2. **Classe com desempenho insuficiente:** Feijão (62.8% AP) e a classe que mais compromete a média geral do modelo. A alta taxa de classificação como background (28%) sugere que o modelo não está conseguindo detectar essa classe com confiabilidade. Recomenda-se aumentar o volume e a variedade de imagens de feijão no dataset de treinamento.
3. **Convergência adequada:** As curvas de perda de treinamento e validação seguiram trajetórias similares, sem indícios de overfitting, o que valida a generalização do modelo.

4. **Aplicabilidade pratica:** As deteccoes em imagens reais confirmaram que o modelo consegue operar em condicoes de iluminacao e fundo variados, embora com niveis de confianca moderados (entre 68% e 79% nos exemplos avaliados).

Como proximos passos para aprimoramento do modelo, sugere-se:

- Ampliar o dataset de treinamento para a classe Feijao, incluindo imagens reais com diferentes marcas, angulos e condicoes de iluminacao.
- Avaliar tecnicas de aumento de dados (data augmentation) direcionadas para as classes com menor desempenho.
- Considerar o treinamento hibrido com imagens sinteticas e reais para reduzir o gap de dominio entre o dataset de treino e o cenario de uso real.