

Relatorio de Eficiencia do Modelo AlimempatIA -- Versao 2

1. Introducao

Este relatorio apresenta uma analise da eficiencia do modelo de deteccao de objetos **AlimempatIA**, desenvolvido para identificar produtos alimenticios da cesta basica em tempo real. O modelo foi treinado utilizando a arquitetura **YOLOv8n** (variante Nano), otimizada para inferencia rapida em dispositivos com recursos limitados. Os resultados aqui descritos referem-se ao treinamento da **versao 2 (v2)** do modelo, denominada internamente de **train_slim**.

As classes detectadas pelo modelo sao:

Indice	Classe
0	Arroz
1	Feijao
2	Acucar
3	Macarrao
4	Fuba
5	Oleo
6	LeiteEmPo

2. Configuracao do Treinamento

O treinamento foi conduzido com os seguintes parametros principais:


Parametro	Valor
Modelo base	YOLOv8n (Nano)
Epocas	40
Tamanho da imagem	512x512 pixels
Batch size	16
Dispositivo	GPU (device 0)
Otimizador	Automatico (auto)
Learning rate	0.01 (inicial)
Peso pre-treinado	Sim (pretrained)
Mosaic	Ativado (1.0)

Parametro	Valor
Augmentacao	RandAugment
Precisao mista	Sim (AMP)

A utilizacao da variante Nano do YOLOv8 foi uma escolha deliberada visando equilibrar desempenho e velocidade de inferencia, dado que o modelo deve operar em cenarios de deteccao em tempo real via camera.

3. Evolucao do Treinamento

O grafico abaixo consolida as curvas de perda (loss) de treinamento e validacao, alem das metricas de precisao, recall e mAP ao longo das 40 epocas:



3.1. Perdas de Treinamento

As tres funcoes de perda monitoradas durante o treinamento (box_loss, cls_loss e dfl_loss) apresentaram queda consistente ao longo das epocas:

- **Box Loss (perda de localizacao):** Reduziu de 0.875 na epoca 1 para 0.364 na epoca 40, indicando que o modelo aprimorou significativamente sua capacidade de localizar os objetos nas imagens.
- **Classification Loss (perda de classificacao):** Apresentou a maior reducao proporcional, caindo de 3.091 para 0.468. Isso demonstra que o modelo aprendeu efetivamente a distinguir entre as sete classes de alimentos.
- **DFL Loss (perda de distribuicao focal):** Reduziu de 1.316 para 0.987, mostrando melhora na precisao das bordas das caixas delimitadoras.

3.2. Perdas de Validacao

As perdas de validacao acompanharam a tendencia de queda das perdas de treinamento, o que indica ausencia de overfitting significativo:

- **Val Box Loss:** De 0.884 para 0.445.
- **Val Cls Loss:** De 3.161 para 0.686.
- **Val DFL Loss:** De 1.238 para 0.970.

A aproximacao entre as curvas de treinamento e validacao sugere que o modelo generalizou adequadamente para dados nao vistos durante o treino.

4. Metricas Finais de Desempenho

Ao final das 40 epocas de treinamento, o modelo atingiu as seguintes metricas globais:

Metrica	Valor Final
Precision	85.19%
Recall	85.45%
mAP@0.5	86.26%
mAP@0.5:0.95	77.26%


Estes valores sao considerados satisfatorios para um modelo da categoria Nano, que prioriza velocidade sobre acuracia maxima. O mAP@0.5 de 86.26% indica que, em media, o modelo identifica corretamente os produtos alimenticios em mais de 86% das vezes quando considerado um limiar de IoU de 50%.

O mAP@0.5:0.95 de 77.26% revela que, mesmo sob criterios mais rigorosos de sobreposicao entre a caixa predita e a caixa real, o modelo mantem um desempenho robusto.

5. Analise por Classe

5.1. Curva Precision-Recall

A curva Precision-Recall abaixo detalha o desempenho individual de cada classe:



Os valores de AP (Average Precision) por classe, extraídos da curva, são:

Classe	AP@0.5
Arroz	98.2%
Feijao	62.8%
Acucar	91.3%
Macarrao	83.5%
Fuba	94.1%
Oleo	99.3%
LeiteEmPo	86.1%
Media	87.9%

Apontamentos:


- **Oleo** e **Arroz** foram as classes com melhor desempenho, atingindo AP superiores a 98%. Isso pode ser atribuído às características visuais distintas dessas embalagens (formato de garrafa para o óleo e pacote padronizado para o arroz), que facilitam a detecção.
- **Feijao** apresentou o menor AP (62.8%), o que representa o principal ponto de atenção do modelo. A queda de desempenho nessa classe pode estar relacionada à similaridade visual entre embalagens de feijão e outros produtos, ou a uma menor representatividade dessa classe no conjunto de dados de

treinamento. Conforme a matriz de confusao normalizada, 28% das amostras reais de feijao foram classificadas como background, indicando falhas na deteccao.

- **Fuba** alcançou um AP elevado de 94.1%, porem a matriz de confusao indica pequenas confusoes com feijao (4%) e acucar (9%), possivelmente devido a semelhancas nas cores das embalagens.

5.2. Curva F1-Confidence

A curva F1 em funcao do limiar de confianca revela o ponto de equilibrio ideal entre precisao e recall:




O F1-Score maximo medio foi de **0.84**, alcançado em um limiar de confianca de **0.696**. Isso significa que, ao configurar o modelo para reportar apenas deteccoes com confianca superior a aproximadamente 70%, obtem-se o melhor balanço entre falsos positivos e falsos negativos.


Destaca-se que a classe **Oleo** mantém um F1-Score acima de 0.90 em uma ampla faixa de confianca (de 0.2 a 0.9), o que confirma a robustez da deteccao dessa classe. Já a classe **Feijao** apresenta valores de F1 consideravelmente mais baixos ao longo de toda a curva, reafirmando a necessidade de melhoria no treinamento para essa categoria.

6. Matriz de Confusao

A matriz de confusao normalizada permite avaliar onde o modelo acerta e onde comete erros sistematicos:



A matriz de confusao em valores absolutos complementa a analise:




Apontamentos sobre a matriz de confusao:

- **Oleo** obteve 100% de acerto na diagonal principal, sem qualquer confusao com outras classes. Este e o melhor resultado individual do modelo.
- **Arroz** apresentou 96% de acerto, com uma pequena confusao de 14% oriunda de amostras de Acucar erroneamente classificadas como Arroz. Essa confusao pode ser explicada pela semelhanca das embalagens brancas de ambos os produtos.
- **Macarrao** atingiu 91% de acerto na classificacao, demonstrando boa capacidade de discriminacao.
- **LeiteEmPo** alcançou 88% de acerto, com 9% de falsos positivos provenientes do background. Isso indica que, em alguns casos, elementos do fundo da imagem sao erroneamente detectados como LeiteEmPo.
- **Fuba** obteve 79% de acerto, com confusoes menores oriundas de Feijao (4%) e Acucar (9%).
- **Acucar** registrou 73% de acerto, com 10% de falsos positivos do background e confusao com Fuba (4%).
- **Feijao** foi a classe com maior taxa de erro: apenas 68% de acerto, com 28% das amostras sendo classificadas como background (nao detectadas) e 40% dos falsos positivos vindo do background. Esse resultado reforca que a classe Feijao necessita de maior volume de dados de treinamento ou maior diversidade de amostras.

7. Deteccoes em Imagens Reais


As imagens a seguir demonstram o modelo em funcionamento sobre capturas reais de camera, validando seu desempenho pratico em cenarios do mundo real.

7.1. Deteccao de Acucar




O modelo identificou corretamente uma embalagem de acucar da marca Alto Alegre com confianca de 79%. A caixa delimitadora abrangeu adequadamente toda a extensao do produto, demonstrando boa localizacao espacial.

7.2. Deteccao de Macarrao



O macarrao da marca Adria foi detectado com confianca de 68%. Embora o valor de confianca seja moderado, a deteccao foi correta tanto na classificacao quanto na localizacao. A confianca ligeiramente inferior pode ser explicada pela iluminacao lateral e pelo fundo parcialmente escuro da imagem.

7.3. Deteccao de Oleo



O óleo de soja da marca Liza foi identificado com 76% de confiança. A caixa delimitadora enquadrando corretamente a garrafa, apesar da presença de sombra e reflexos na embalagem transparente, que podem dificultar a detecção.

8. Considerações Finais

O modelo AlimempatIA v2, baseado na arquitetura YOLOv8n, demonstrou eficiência satisfatória na detecção de 7 classes de produtos alimentícios da cesta básica. Com um mAP@0.5 de 87.9% e mAP@0.5:0.95 de 77.26%, o modelo apresenta um bom equilíbrio entre acurácia e velocidade de inferência.

Os principais pontos de destaque são:

1. **Classes com alto desempenho:** Óleo (99.3% AP), Arroz (98.2% AP) e Fuba (94.1% AP) foram consistentemente bem detectados, com baixíssimas taxas de confusão.
2. **Classe com desempenho insuficiente:** Feijão (62.8% AP) e a classe que mais compromete a média geral do modelo. A alta taxa de classificação como background (28%) sugere que o modelo não está conseguindo detectar essa classe com confiabilidade. Recomenda-se aumentar o volume e a variedade de imagens de feijão no dataset de treinamento.
3. **Convergência adequada:** As curvas de perda de treinamento e validação seguiram trajetórias similares, sem indícios de overfitting, o que valida a generalização do modelo.

4. **Aplicabilidade pratica:** As deteccoes em imagens reais confirmaram que o modelo consegue operar em condicoes de iluminacao e fundo variados, embora com niveis de confianca moderados (entre 68% e 79% nos exemplos avaliados).

Como proximos passos para aprimoramento do modelo, sugere-se:

- Ampliar o dataset de treinamento para a classe Feijao, incluindo imagens reais com diferentes marcas, angulos e condicoes de iluminacao.
- Avaliar tecnicas de aumento de dados (data augmentation) direcionadas para as classes com menor desempenho.
- Considerar o treinamento hibrido com imagens sinteticas e reais para reduzir o gap de dominio entre o dataset de treino e o cenario de uso real.